



Instituto Tecnológico
de Buenos Aires

Análisis espectral y clasificación con Machine Learning de EEG en reposo para la privación del sueño

16.63 - Procesamiento y Análisis de Señales Biomédicas

Grupo 9

Integrantes:

Batamarca, Benito	63261
Berraud, Constanza	63035
Von Wernich, Joaquin	64041

2026 1Q

Índice

Índice.....	1
1. Introducción.....	2
1.1. Marco teórico.....	2
1.2. Estado del arte.....	3
1.3. Objetivos.....	3
2. Materiales y métodos.....	3
2.1. Dataset.....	3
2.2. Herramientas.....	4
2.3. Pipeline de preprocesamiento.....	4
2.4. Análisis espectral y topografías.....	5
2.5. Extracción de características.....	5
2.6. Clasificación con Machine Learning.....	6
3. Resultados.....	7
3.1. Análisis espectral.....	7
3.2. Clasificación con Machine Learning.....	7
Matriz de confusión de Random Forest (Figura 3 del Anexo).....	8
Variables más informativas, importancia por permutación (Figura 4 del Anexo).....	8
5. Anexo.....	10
5.1. Estructura del código y ejecución.....	10
6. Bibliografía.....	12

1. Introducción

1.1. Marco teórico

La electroencefalografía (EEG) es una técnica no invasiva que permite registrar las variaciones de potencial eléctrico generadas por la actividad neuronal mediante electrodos colocados sobre el cuero cabelludo. Gracias a su elevada resolución temporal, del orden de los milisegundos, constituye una herramienta ampliamente utilizada para estudiar la dinámica de los procesos cerebrales y los cambios en los estados de vigilancia, atención y sueño. Sin embargo, su resolución espacial es limitada debido a la conducción de las señales eléctricas a través de los tejidos que separan la corteza cerebral de los electrodos.

La señal de EEG refleja principalmente la suma espacial y temporal de los potenciales postsinápticos producidos por grandes poblaciones de neuronas corticales, especialmente neuronas piramidales orientadas perpendicularmente a la superficie de la corteza. Para que esta actividad sea detectable en el cuero cabelludo es necesario que exista un cierto grado de sincronización entre las neuronas involucradas.

El EEG de reposo, registrado sin que el sujeto realice ninguna tarea específica, representa el estado basal de la actividad cerebral y resulta especialmente sensible a cambios fisiológicos como la somnolencia y la privación de sueño. Debido al carácter oscilatorio de la señal, una de las formas más utilizadas para su estudio consiste en analizar su contenido frecuencial mediante la Densidad Espectral de Potencia (PSD), que describe cómo se distribuye la energía de la señal en función de la frecuencia. Este análisis permite identificar y cuantificar los distintos ritmos cerebrales presentes en el registro.

Tradicionalmente, el espectro del EEG se divide en bandas de frecuencia con significados fisiológicos diferenciados. La banda delta (0,5–4 Hz) se asocia principalmente al sueño profundo; la banda theta (4–8 Hz) a estados de somnolencia y reducción de la vigilancia; la banda alfa (8–13 Hz) predomina durante estados de relajación con ojos cerrados; la banda beta (13–30 Hz) se relaciona con procesos de atención y actividad cognitiva; y la banda gamma (>30 Hz) con mecanismos complejos de integración neuronal y procesamiento de información.

En el contexto de la privación de sueño (Sleep Deprivation, SD), el análisis espectral resulta especialmente útil, ya que esta condición modifica de manera característica la actividad cerebral. En comparación con individuos con sueño normal (Normal Sleep, NS), suele observarse un aumento de la actividad lenta, particularmente en la banda theta, asociado a una mayor presión de sueño, además de cambios en la actividad alfa y un incremento de la potencia absoluta total.

Además de la información espectral, también resulta de interés analizar la distribución espacial de la actividad cerebral mediante mapas topográficos o topomapas. Estas representaciones asignan a cada electrodo un valor determinado e interpolan los datos entre posiciones vecinas para obtener una visualización continua de la actividad sobre el cuero cabelludo. Los topomapas permiten identificar patrones espaciales característicos de diferentes estados fisiológicos, así como detectar posibles artefactos de registro.

El EEG crudo contiene artefactos que no son de origen cerebral, principalmente parpadeos, movimientos oculares y actividad muscular. Para reducir su influencia es habitual emplear el Análisis de Componentes Independientes (ICA), que descompone la señal en componentes estadísticamente independientes, permitiendo identificar y eliminar aquellas asociadas a artefactos, conservando en la mayor medida posible la actividad cerebral de interés.

Finalmente, el análisis del EEG puede complementarse mediante técnicas de aprendizaje automático (Machine Learning). A partir de características (features) extraídas de la señal, como la potencia en distintas bandas de frecuencia u otros descriptores espectrales y temporales, es posible entrenar clasificadores capaces de aprender patrones presentes en los datos para distinguir automáticamente entre diferentes condiciones, como sujetos con privación de sueño (SD) y sujetos con sueño normal (NS), en lugar de utilizar reglas definidas manualmente.

1.2. Estado del arte

El trabajo se basa en el dataset y el análisis de Xiang y colaboradores (2024) en *Scientific Data*, un *data descriptor* con registros de EEG de reposo de 71 participantes en dos sesiones (descanso y privación) más datos conductuales. El paper documenta que la potencia absoluta durante la privación es en general mayor que en descanso, con pico ~10 Hz y máximos de alpha/theta en zonas frontal y occipital.

La literatura previa establece que la privación de sueño afecta principalmente las bandas theta y alfa del EEG de reposo, con marcada variabilidad individual. En lo metodológico, la eliminación de artefactos por ICA con clasificación automática de componentes (ICLabel) y el uso de clasificadores estándar para datos tabulares son prácticas consolidadas en el análisis de EEG.

1.3. Objetivos

El trabajo se desarrolló en dos etapas. En la primera, por consigna, no estaba permitido utilizar ICA ni técnicas de aprendizaje automático (Machine Learning). En consecuencia, el procesamiento de las señales se realizó sin eliminación de artefactos mediante ICA y la clasificación entre las condiciones de privación de sueño (Sleep Deprivation, SD) y sueño normal (Normal Sleep, NS) se efectuó mediante umbrales definidos manualmente a partir de las características extraídas del EEG.

En la segunda etapa se habilitó el uso de ambas herramientas con el objetivo de replicar de manera más fiel el pipeline de preprocesamiento y análisis espectral propuesto en el paper de referencia. Para ello se incorporó ICA con el fin de identificar y eliminar artefactos oculares y musculares, preservando la actividad cerebral de interés. Además, se desarrolló un clasificador basado en Machine Learning capaz de distinguir automáticamente entre las condiciones SD y NS a partir de las características extraídas de la señal. Finalmente, se comparó el desempeño obtenido con el de la etapa previa, realizada sin ICA ni Machine Learning, así como con los resultados reportados en el paper de referencia.

2. Materiales y métodos

2.1. Dataset

Se utilizó el dataset OpenNeuro ds004902 (Xiang et al., 2024), organizado en formato BIDS. El conjunto original contiene 71 sujetos pero en este trabajo se analizaron 30 (sub-01 a

sub-30). Cada sujeto dispone de dos sesiones: descanso normal (NS, ses-1) y privación de sueño (SD, ses-2), siguiendo un diseño *within-subject*. Se analizó el ensayo de ojos abiertos (*eyesopen*). Los registros tienen una duración de 300 segundos, una frecuencia de muestreo de 500 Hz y fueron adquiridos con un montaje estándar extendido 10-20 de 61 canales. Los datos se distribuyen en formato EEGLAB/BIDS y ya incluyen el acondicionamiento realizado durante la adquisición: referencia online en FCz y filtro notch de 50 Hz aplicado. Por este motivo, en el presente trabajo no se volvió a aplicar el filtro notch. Además, según el descriptor del dataset, los registros no recibieron preprocesamiento *offline*, por lo que las etapas de filtrado, re-referenciación y eliminación de artefactos fueron implementadas como parte del pipeline desarrollado.

2.2. Herramientas

Se trabajó en Python, utilizando MNE-Python para el procesamiento de las señales de EEG, mne-icalabel (ICLabel) para la clasificación automática de los componentes obtenidos mediante ICA y scikit-learn para el desarrollo del clasificador de Machine Learning. Además, se desarrolló una interfaz gráfica mediante Tkinter, que permite ejecutar, visualizar e integrar de forma interactiva todas las etapas del pipeline de procesamiento y análisis.

2.3. Pipeline de preprocesamiento

Metodología desarrollada en el paper	Metodología desarrollada en este trabajo
Filtrado pasabanda 0,2–45 Hz (FIR)	Filtrado pasabanda 0,2–45 Hz (FIR).
75 épocas de 4 segundos	75 épocas de 4 segundos
Rechazo de épocas (inspección visual)	Umbral pico-pico (automático)
Interpolación de canales malos	Detección por varianza + interpolación esférica
ICA (infomax) con selección manual	ICA infomax extendido + ICLabel (automática)
Re-referencia al promedio	Re-referencia al promedio

Tabla 1: Comparación entre la metodología de preprocesamiento propuesta por Xiang et al. (2024) y la metodología implementada en este trabajo.

El preprocesamiento comenzó con la aplicación de un filtro pasabanda FIR de 0,2–45 Hz, con el objetivo de eliminar la deriva de baja frecuencia y el ruido de alta frecuencia. Posteriormente, cada registro continuo de aproximadamente 300 segundos se segmentó en 75 épocas de 4 segundos, duración que proporciona una resolución espectral adecuada para el análisis de las bandas de interés y facilita el aislamiento de artefactos.

A continuación, se realizó un rechazo automático de épocas mediante un umbral robusto basado en la amplitud pico-pico, calculado a partir de la mediana y la desviación absoluta mediana (MAD), evitando la necesidad de inspección visual. Los canales malos se identificaron a partir de su varianza y fueron reconstruidos mediante interpolación esférica, preservando la información espacial del registro.

La eliminación de artefactos se efectuó mediante ICA (*Figura 5* del Anexo) utilizando el algoritmo Infomax extendido, seguido de la clasificación automática de los componentes con ICLabel. Se eliminaron únicamente aquellos clasificados como artefactos oculares y musculares con una confianza igual o superior al 80 %, automatizando el procedimiento realizado manualmente en el paper de referencia. Finalmente, los registros fueron re-referenciados al promedio de todos los canales, obteniéndose la señal utilizada para el cálculo del PSD y el análisis posterior.

2.4. Análisis espectral y topografías

Sobre la señal limpia con ICA se calculó la PSD por Welch (ventana 4 segundos), en dB ($10 \cdot \log_{10}$ de $\mu V^2/Hz$). Se analizaron theta, alfa y beta (potencia absoluta y relativa). Se generaron topografías por banda y condición para cada sujeto, un promedio grupal del PSD de Cz (*Figura 1* del Anexo) y de las topografías sobre los 30 sujetos (*Figura 2* del Anexo).

2.5. Extracción de características

Cada registro se representó mediante un vector de 49 características extraídas del PSD posterior a la aplicación de ICA, ya que los clasificadores operan sobre vectores numéricos de tamaño fijo y no sobre la señal EEG cruda. Las características corresponden exclusivamente a potencias espectrales, incluyendo potencia por banda y región (absoluta en dB y relativa), potencias en los canales de línea media (Fz, Cz, Pz y Oz), promedios de regiones posteriores, razones espectrales (alpha/theta y theta/beta) y potencia total. La potencia absoluta se expresó en decibeles para reducir su amplio rango dinámico, mientras que la potencia relativa se utilizó como una medida normalizada. La selección de estas variables se basó en su respaldo fisiológico y en la evidencia reportada por el paper de referencia, que las identifica como marcadores sensibles a la privación de sueño. Estas se organizaron en seis grupos:

Grupo de características	Cantidad	Justificación
Banda x región (dB)	15	Potencia absoluta (dB) de $\theta/\alpha/\beta$ en cada una de las 5 regiones (frontal, central, temporal, parietal, occipital). Describe la distribución espacial de cada banda, que es lo que cambia con la somnolencia.
Banda x región (relativa)	15	Proporción de cada banda respecto al total. Es robusta a diferencias globales de amplitud entre sujetos (dos personas con distinta amplitud pero igual 'forma' espectral quedan comparables).
Línea media x banda (dB)	12	$\theta/\alpha/\beta$ en Cz, Pz, Oz y Fz. Los canales de la línea media están poco contaminados por los ojos; el paper reporta su espectro principal en Cz.

Posteriores (dB)	3	$\theta/\alpha/\beta$ promediados en canales posteriores: zonas limpias y sensibles a la actividad lenta de somnolencia.
Razones espectrales	2	Alpha/theta y theta/beta: índices clásicos de presión de sueño (theta sube y alpha baja al aumentar la somnolencia).
Potencia total	2	Potencia total global y en Cz. El paper reporta mayor potencia absoluta en SD que en NS.

Tabla 2: Resumen de las 49 características empleadas en el modelo de clasificación según su grupo, cantidad y fundamento fisiológico.

2.6. Clasificación con Machine Learning

Cada muestra correspondió a un registro de EEG de un sujeto en una condición experimental. Dado que se analizaron 30 sujetos con dos condiciones (NS y SD), el conjunto de datos estuvo compuesto por 60 muestras, cada una representada por las 49 características espectrales extraídas del PSD posterior a la aplicación de ICA. La variable objetivo fue la condición experimental, considerando a la privación de sueño (SD) como la clase positiva.

Para el entrenamiento de los modelos se implementó un procedimiento de preprocesamiento de las características. En primer lugar, los valores faltantes se imputaron utilizando la mediana. Posteriormente, en los modelos sensibles a la escala de las variables (Regresión Logística y Máquinas de Vectores de Soporte, SVM), las características se estandarizaron para obtener media cero y varianza uno. Tanto la imputación como la estandarización se ajustaron únicamente con los datos de entrenamiento de cada partición de validación, evitando la pérdida de información hacia el conjunto de prueba.

Se comparó el desempeño de cuatro algoritmos de clasificación: Regresión Logística, SVM con kernel de función de base radial (RBF), Random Forest y Gradient Boosting. La Regresión Logística se seleccionó como modelo lineal e interpretable, SVM permitió modelar relaciones no lineales, mientras que Random Forest y Gradient Boosting constituyeron métodos de ensamble basados en árboles de decisión.

La evaluación de los modelos se realizó mediante validación cruzada Leave-One-Subject-Out (LOSO). En cada una de las 30 iteraciones se excluyeron del entrenamiento los dos registros correspondientes a un mismo sujeto (NS y SD), utilizándolos únicamente para la prueba, mientras que el modelo se entrenó con los registros de los 29 sujetos restantes. De esta manera se evitó que el modelo aprendiera características propias de un mismo individuo, lo que habría producido una sobreestimación del desempeño. Para cada registro se obtuvo una probabilidad de pertenecer a la clase SD

mediante predicciones *out-of-fold*, generadas por un modelo que no había sido entrenado con ese sujeto.

Finalmente, el desempeño de los clasificadores se evaluó mediante las métricas de exactitud (*accuracy*), área bajo la curva ROC (AUC) y exactitud pareada, esta última aprovechando el diseño *within-subject* para determinar correctamente cuál de los dos registros de cada participante correspondía a la condición de privación de sueño. El modelo con mayor AUC fue seleccionado y posteriormente reentrenado utilizando las 60 muestras para su aplicación final.

3. Resultados

3.1. Análisis espectral

El aumento de theta y de la potencia total durante la privación coincide con el hallazgo principal del paper (potencia absoluta SD $\geq$ NS). La alta variabilidad individual, también señalada por el paper, se observa en la dispersión entre sujetos.

Métrica (promedio de sujetos)	NS	SD	Tendencia
Theta en región central (dB)	1,72	3,36	SD > NS
Potencia total en Cz (dB)	11,76	12,81	SD > NS
Alpha occipital (dB)	7,58	7,49	$\approx$ sin cambio

Tabla 3: Comparación de las principales métricas espectrales promedio entre las condiciones de descanso normal (NS) y privación de sueño (SD), junto con la tendencia observada.

3.2. Clasificación con Machine Learning

Se compararon los cuatro modelos con validación LOSO. El mejor por AUC fue Random Forest:

Modelo	AUC	Exactitud	Exactitud pareada
Random Forest	0,634	58 %	77 %
Regresión Logística	0,618	58 %	60 %
Gradient Boosting	0,569	58 %	60 %
SVM (RBF)	0,352	40 %	30 %

Tabla 4: Desempeño de los modelos de clasificación evaluados mediante validación Leave-One-Subject-Out (LOSO), comparados según el área bajo la curva ROC (AUC), la exactitud y la exactitud pareada.

De los cuatro clasificadores evaluados, Random Forest fue seleccionado como modelo final por presentar el mayor desempeño en términos de AUC. Este es un método de ensamble que combina las predicciones de múltiples árboles de decisión, lo que proporciona un

modelo más estable y robusto que un árbol individual. Cada árbol clasifica los registros mediante una secuencia de decisiones sobre las características espectrales, seleccionando en cada nodo el punto de corte que maximiza la pureza de los grupos según el criterio de Gini. Con el fin de reducir el sobreajuste, cada árbol se entrena utilizando una muestra obtenida por bootstrap y, en cada nodo, considera únicamente un subconjunto aleatorio de características. La predicción final se obtiene promediando las probabilidades estimadas por todos los árboles y aplicando un umbral de decisión de 0,5.

Este clasificador resultó especialmente adecuado para el problema abordado, ya que el conjunto de datos estaba compuesto por un número reducido de muestras (60 registros) y un conjunto relativamente amplio de características (49 variables), muchas de ellas correlacionadas entre sí. Además de capturar relaciones no lineales entre las variables, Random Forest es robusto frente a características redundantes y valores atípicos, no requiere estandarización de las variables de entrada y permite estimar la importancia relativa de cada característica para la clasificación.

El modelo se configuró con 200 árboles de decisión ($n_estimators = 200$), una profundidad máxima de cuatro niveles ($max_depth = 4$), un mínimo de tres muestras por hoja ($min_samples_leaf = 3$), criterio de división Gini, selección aleatoria de aproximadamente 7 características por nodo ($max_features$), ponderación balanceada de las clases ($class_weight = "balanced"$) y una semilla fija ($random_state = 0$) para garantizar la reproducibilidad de los resultados. Estos parámetros se eligieron con el objetivo de limitar el sobreajuste, verificándose además que incrementar el número de árboles a 400 no producía mejoras apreciables en el desempeño.

El modelo final alcanzó una exactitud del 58 % (35 de 60 registros correctamente clasificados), un área bajo la curva ROC (AUC) de 0,63 y una exactitud pareada del 77 % (23 de 30 sujetos). Esta última métrica, al aprovechar el diseño *within-subject*, evalúa la capacidad del clasificador para identificar correctamente cuál de los dos registros de un mismo sujeto corresponde a la condición de privación de sueño, por lo que constituye una medida especialmente informativa en estudios con un número reducido de participantes.

Matriz de confusión de Random Forest (Figura 3 del Anexo)

El modelo reconoce mejor el descanso (20/30 NS correctos) que la privación (15/30 SD): los falsos negativos de SD son la principal fuente de error, coherente con que algunos sujetos responden poco a la privación.

Variables más informativas, importancia por permutación (Figura 4 del Anexo)

Las variables más informativas fueron aquellas cuyas características espectrales mostraron diferencias consistentes entre las condiciones de descanso normal (NS) y privación de sueño (SD). Entre ellas se destacaron las relacionadas con la banda alfa y los canales posteriores y occipitales, debido a que el ritmo alfa es un reconocido marcador del estado de vigilancia y presenta variaciones con la somnolencia. Asimismo, la región occipital constituye el principal generador de esta actividad y, al encontrarse alejada de los ojos, presenta menor contaminación por artefactos oculares. También resultaron relevantes las variables asociadas a la banda theta, cuyo incremento se relaciona con un aumento de la presión de sueño, y algunas características de la banda beta y del alfa frontal, que reflejan cambios en el nivel de alerta.

4. Conclusiones

En primer lugar, se completó la réplica del pipeline del paper incorporando ICA (infomax + ICLabel), de modo que el preprocesamiento sigue el original paso a paso y de forma reproducible, adaptando lo que se mencionó anteriormente. En cuanto al análisis espectral, se reprodujeron las tendencias claves (aumento de theta y de potencia total con la privación). Segundo, se construyó un sistema de clasificación con Machine Learning: características con respaldo fisiológico, comparación objetiva de modelos y validación honesta por sujeto.

Sobre el desempeño: clasificar cada registro aislado es difícil (exactitud 58 %, apenas sobre el azar), lo que refleja la fuerte variabilidad individual en la respuesta a la privación (limitación que el propio paper remarca). Sin embargo, aprovechando el diseño pareado, el modelo distingue correctamente la condición dentro de cada persona en el 77 % de los sujetos, un resultado sólido para $N=30$. El AUC de 0,63 confirma la capacidad discriminativa por encima del azar.

Respecto de la etapa previa, se cambió de una clasificación por umbrales manuales (una métrica elegida a mano, sin validación) a un modelo entrenado y validado correctamente, y se completó la réplica del paper al incorporar la ICA. Las mejoras futuras más prometedoras son incorporar los 41 sujetos restantes del dataset y explotar la normalización intra-sujeto.

5. Anexo

5.1. Estructura del código y ejecución

El paquete `psib_eeg/` separa el núcleo de análisis (`core/`: `io`, `bands`, `preprocessing`, `spectral`, `topo`, `ml`, `pipeline`) de la interfaz gráfica (`gui/`, con 7 pestañas: Señal, PSD, Bandas, Topomapas, ICA, Todos los sujetos, Clasificación ML). Al ejecutarla por primera vez, la aplicación realiza automáticamente todo el precálculo (ICA de los 60 registros, promedio grupal y entrenamiento del modelo) y lo deja cacheado para aperturas instantáneas.




Figura 1: PSD del canal Cz obtenida para los registros de descanso normal (NS) y privación de sueño (SD).




Figura 2: Comparación de los topomapas de potencia espectral (dB) en las bandas theta, alfa y beta entre las condiciones de sueño normal (NS) y privación de sueño (SD).




Figura 3: Pestaña "Desempeño" de la interfaz gráfica desarrollada, donde se presentan el modelo seleccionado, las métricas de desempeño (AUC, exactitud y exactitud pareada), la comparación entre clasificadores, la matriz de confusión y la curva ROC.



Figura 4: Pestaña "Importancia de variables" de la interfaz gráfica desarrollada, que muestra la importancia de las características calculada mediante permutación, expresada como la disminución del AUC (ΔAUC) al desordenar cada variable.




Figura 5: Visualización de la etapa de limpieza mediante ICA en la interfaz gráfica (sujeto 6). Se presentan los mapas topográficos de los componentes clasificados como artefactos y eliminados automáticamente mediante ICLabel.

6. Bibliografía

- Xiang, C., Fan, X., Bai, D., Lv, K., & Lei, X. (2024). A resting-state EEG dataset for sleep deprivation. *Scientific Data*, 11(1), 427.
<https://doi.org/10.1038/s41597-024-03268-2>
- OpenNeuro. (s. f.). <https://openneuro.org/datasets/ds004902/versions/1.0.8>